

Algorytmy Probabilistyczne

Naiwny Klasyfikator Bayesowski i Sieci Bayesowskie

Metody Sztucznej Inteligencji

Prowadzący: *Szymon Zaporowski*

Katedra Systemów Multimedialnych / WETI

Semestr 1, stopień II, rok akademicki 2025/2026

Plan wykładu

- 1 Motywacja i podstawy probabilistyczne
- 2 Naiwny Klasyfikator Bayesowski
- 3 Sieci Bayesowskie
- 4 Zastosowania i podsumowanie

Dlaczego probabilistyka w Sztucznej Inteligencji?

Problemy rzeczywistego świata

- Dane są **niepełne** i **zaszumione**
- Obserwacje nie determinują jednoznacznie wyniku
- Potrzebujemy *miary pewności* decyzji

Kluczowa idea

Klasyfikacja = **inferencja probabilistyczna**

Zamiast pytać „Co to jest?”,
pytamy: „Z jakim prawdopodobieństwem to jest X?”

Przykłady zastosowań

- Filtr spamu
- Diagnostyka medyczna
- Analiza sentymentu
- Wykrywanie oszustw
- Rozpoznawanie mowy

Twierdzenie Bayesa — fundament

Twierdzenie Bayesa

$$P(C \mid x) = \frac{P(x \mid C) P(C)}{P(x)}$$

- $P(C)$ — wiedza *a priori* o klasie
- $P(x \mid C)$ — zgodność danych z klasą
- $P(C \mid x)$ — posterior po obserwacji
- $P(x)$ — stała normalizująca

Reguła MAP

$$\hat{C} = \arg \max_C P(C \mid x)$$

W praktyce często porównujemy tylko liczniki,
bo $P(x)$ nie zależy od klasy.

Naiwny Klasyfikator Bayesowski – założenie kluczowe


„Naiwne” założenie warunkowej niezależności cech

$$P(x | C) = P(x_1 | C) \cdot P(x_2 | C) \cdots P(x_n | C) = \prod_{i=1}^n P(x_i | C)$$

Cechy $x_1, x_2, \dots, x_n$ są **warunkowo niezależne** przy danej klasie C

Konsekwencje:

- Zamiast jednej dużej CPT $\Rightarrow n$ małych 1D rozkładów
- Liczba parametrów: $\mathcal{O}(n \cdot k)$ zamiast $\mathcal{O}(k^n)$
- Bardzo efektywny obliczeniowo



Graf NB jako sieć bayesowska

Warianty NB i wygładzanie Laplace'a

Warianty modelu

Wariant	Dane
Gaussian NB	cechy ciągłe
Multinomial NB	zliczenia, tekst
Bernoulli NB	cechy binarne

Zero-frequency problem

Jeśli dla pewnej cechy mamy $P(x_i | C) = 0$, cały iloczyn prawdopodobieństw spada do zera.

Wygładzanie Laplace'a

$$P(x_i | C) = \frac{N_{ic} + \alpha}{N_c + \alpha k}$$

gdzie:

N_{ic} — liczba wystąpień danej wartości w klasie C ,

N_c — liczba przykładów klasy C ,

k — liczba możliwych wartości cechy.

Praktyka: liczymy sumę logarytmów, $\sum_i \log P(x_i | C)$, a nie iloczyn.

Przykład: Klasyfikacja e-maila jako spam (1/2)

Zbiór treningowy

E-mail	„oferta”	„gratulacje”	„spotkanie”	Klasa
1	1	1	0	spam
2	1	0	0	spam
3	0	1	0	spam
4	0	0	1	ham
5	0	0	1	ham
6	1	0	1	ham

Cechy binarne: 1 = słowo występuje w e-mailu, 0 = nie występuje

Klasy: *spam* (niechciana wiadomość) vs. *ham* (poprawna wiadomość)

Przykład: Klasyfikacja e-maila jako spam (2/2)

Nowy e-mail do sklasyfikowania

„oferta” = 1, „gratulacje” = 0, „spotkanie” = 1

Prior (z danych treningowych)

$$P(\text{spam}) = \frac{3}{6} = 0,5$$

$$P(\text{ham}) = \frac{3}{6} = 0,5$$

Zadanie

Korzystając z założenia warunkowej niezależności oblicz:

$$\hat{C} = \arg \max_C P(C | x)$$

Rozwiązanie na następnym slajdzie.

Przykład: Rozwiązanie (z wygładzaniem $\alpha = 1$)

Likelihood dla spam ($N_c = 3$,
 $k = 2$)

$$P(\text{of.} = 1|\text{spam}) = \frac{2+1}{3+2} = \frac{3}{5}$$

$$P(\text{gr.} = 0|\text{spam}) = \frac{1+1}{3+2} = \frac{2}{5}$$

$$P(\text{sp.} = 1|\text{spam}) = \frac{0+1}{3+2} = \frac{1}{5}$$

$$\Rightarrow P(\text{spam}|x) \propto 0,5 \cdot \frac{3}{5} \cdot \frac{2}{5} \cdot \frac{1}{5} = 0,024$$

Likelihood dla ham ($N_c = 3$, $k = 2$)

$$P(\text{of.} = 1|\text{ham}) = \frac{1+1}{3+2} = \frac{2}{5}$$

$$P(\text{gr.} = 0|\text{ham}) = \frac{3+1}{3+2} = \frac{4}{5}$$

$$P(\text{sp.} = 1|\text{ham}) = \frac{3+1}{3+2} = \frac{4}{5}$$

$$\Rightarrow P(\text{ham}|x) \propto 0,5 \cdot \frac{2}{5} \cdot \frac{4}{5} \cdot \frac{4}{5} = 0,128$$

Decyzja MAP

$0,128 > 0,024 \Rightarrow$ **Klasyfikuj jako HAM (nie-spam)**

Sieć Bayesowska – definicja

Definicja

Sieć Bayesowska to para $(\mathcal{G}, \theta)$:

- $\mathcal{G} = (V, E)$ – **DAG** (Directed Acyclic Graph)
 V = zmienne losowe, E = zależności przyczynowe
- θ – tablice **CPT** (Conditional Probability Tables):
dla każdego węzła X_i : $P(X_i \mid \text{Pa}(X_i))$

Rozkład łączny

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i))$$

Własność Markowa: każdy węzeł jest warunkowo niezależny od swoich nie-potomków przy znanych rodzicach.

Trzy typy połączeń w DAG

- **Serial:** $A \rightarrow B \rightarrow C$
Informacja płynie przez B ;
jeśli B znane – $A \perp C$
- **Rozwidlenie:** $A \leftarrow B \rightarrow C$
 B jest wspólną przyczyną;
jeśli B znane – $A \perp C$
- **Zbieżność:** $A \rightarrow B \leftarrow C$
 A i C niezależne a priori,
ale zależne gdy B obserwowane
(*explaining away*)

d-separation


Kryterium **d-separacji** określa, kiedy dwa węzły są warunkowo niezależne przy danym zbiorze obserwowanych zmiennych.

Przykład: Explaining away

Alarm $\rightarrow$ John dzwoni $\leftarrow$ Mary dzwoni

John i Mary dzwonią niezależnie,
ale wiedząc, że John dzwonił,
zmienia się prawdopodobieństwo
że Mary też zadzwoni.

Przykład klasyczny: Sieć alarmowa



CPT dla węzła Alarm

B	E	$P(\text{Alarm} = T)$
T	T	0.95
T	F	0.94
F	T	0.29
F	F	0.001

Prior: $P(B = T) = 0.001$, $P(E = T) = 0.002$

Pytanie: Jeśli alarm dzwoni — czy to włamanie?

⇒ Wymaga wnioskowania wstecznego

Wnioskowanie w sieciach bayesowskich (1/2)

Rodzaje wnioskowania

- **Diagnostyczne** (bottom-up): objawy $\rightarrow$ przyczyny
- **Przyczynowe** (top-down): przyczyny $\rightarrow$ efekty
- **Mieszane** (abdukcja): marginalizacja po ukrytych zmiennych

Wnioskowanie dokładne

Enumeracja: $P(Q \mid e) = \alpha \sum_h P(Q, h, e)$

Eliminacja zmiennych: optymalizacja kolejności sumowania, redukuje złożoność

Złożoność: wykładnicza w ogólnym przypadku (NP-trudne)

Wnioskowanie aproksymacyjne (2/2)

Metody próbkowania Monte Carlo


- **Direct Sampling**
losowe próbki z rozkładu a priori
- **Rejection Sampling**
odrzucaamy próbki niezgodne z e
- **Likelihood Weighting**
ustalamy e , ważymy próbki
- **Gibbs Sampling (MCMC)**
próbkowanie warunkowe kolejnych zmiennych

Kiedy stosować aproksymację?

- Sieć ma wiele węzłów (>20) – wnioskowanie dokładne zbyt wolne
- Wiele zmiennych ukrytych – przestrzeń sum wykładnicza
- W praktyce: **Gibbs Sampling** najczęściej używany

Relacja: $NB \subset$ Sieci Bayesowskie


Naiwny Bayes



brak krawędzi między cechami

Wszystkie cechy niezależne
(CPT = 1D rozkłady)

TAN (Tree-Augmented NB)



Dodatkowe krawędzie (drzewo)
(lepsza aproksymacja zależności)

Hierarchia modeli

Naiwny Bayes $\subset$ TAN $\subset$ Ogólna Sieć Bayesowska

Zastosowania w praktyce

Naiwny Bayes

- Filtrowanie spamu
- Klasyfikacja tekstu i NLP
- Analiza sentymentu
- Wstępna diagnostyka
- Kategoryzacja dokumentów

Sieci Bayesowskie

- Wspomaganie decyzji klinicznych
- Modele przyczynowości (XAI)
- Ocena ryzyka
- Robotyka i lokalizacja
- Diagnoza awarii

Generatywne vs. dyskryminatywne

	NB	Reg. logistyczna
Modeluje	$P(C, x)$	$P(C x)$
Dane	małe zbiory	większe zbiory
Interpretowalność	wysoka	średnia

Ograniczenia

Naiwny Bayes:

- Założenie niezależności (rzadko spełnione)
- Złe oszacowania, gdy cechy skorelowane

Sieci Bayesowskie:

- Uczenie struktury – NP-trudne
- CPT rośnie wykładniczo z liczbą rodziców
- Wnioskowanie dokładne – wykładnicze

Rozszerzenia

- **TAN** – Tree-Augmented Naive Bayes
- **DBN** – Dynamic Bayesian Networks (HMM)
- **NB + EM** – niekompletne dane
- **Bayesowskie sieci głębokie** – połączenie z DL
- **Causal Discovery** (PC algorithm, FCI)

Narzędzia: GeNIe/SMILE, pgmpy (Python), bnlearn (R)

Kluczowe pojęcia

Pojęcie	Istota
Tw. Bayesa	Aktualizacja wiary po obserwacji danych
MAP	Decyzja maksymalizująca posterior
Naiwny Bayes	NB = warunkowa niezależność cech
CPT	Lokalna specyfikacja zależności w DAG
Wnioskowanie	Exact (eliminacja) vs. approx (MCMC)

Myśl przewodnia

*„Sieci Bayesowskie to uogólnienie Naiwnego Bayesa — tam gdzie NB tnie **wszystkie** krawędzie między cechami, sieć pozwala **precyzyjnie kontrolować** strukturę zależności.”*

Lab: `sklearn.naive_bayes` | GeNIe/SMILE (bayesfusion.com)

Podręczniki

- S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed., Pearson 2020. Rozdz. 12–13
- T. Mitchell, *Machine Learning*, McGraw-Hill 1997. Rozdz. 6
- C. Bishop, *Pattern Recognition and Machine Learning*, Springer 2006. Rozdz. 8

Materiały polskojęzyczne

- W. Duch, *Analiza Bayesa – SI*, UMK Toruń (slajdy online)
- *Notatki: Naiwny Klasyfikator Bayesowski*, PJATK Warszawa
users.pja.edu.pl/~msyd/
- *Sieci Bayesowskie – Wykład XI*, MIMUW Warszawa
- *Klasyfikacja Bayesowska*, WikiZMSI, ZUT Szczecin

? Pytania i dyskusja

Metody Sztucznej Inteligencji

Algorytmy Probabilistyczne

Naiwny Klasyfikator Bayesowski i Sieci Bayesowskie